

UNIVERSIDADE PRESBITERIANA MACKENZIE

Faculdade de Computação e Informática

Curso de Ciência de Dados

ENZO ENRICO BRAGA CAVALCANTE

RA: 10744145

PROJETO APLICADO III

**SISTEMA DE RECOMENDAÇÃO DE LIVROS BASEADO EM
FILTRAGEM COLABORATIVA:
uma aplicação para o incentivo à leitura em bibliotecas públicas e
escolares**

Guarulhos

2026

SUMÁRIO

1 INTRODUÇÃO.....	3
1.1 Contexto do trabalho.....	3
1.2 Motivação.....	3
1.3 Justificativa.....	4
1.4 Objetivos.....	5
1.4.1 Objetivo geral.....	5
1.4.2 Objetivos específicos.....	5
1.5 Objetivo extensionista e alinhamento com os ODS.....	6
1.6 Apresentação do conjunto de dados.....	6
1.7 Organização do projeto.....	7
1.7.1 Grupo de trabalho.....	7
1.7.2 Repositório de materiais.....	8
1.7.3 Cronograma.....	8
REFERÊNCIAS.....	9

1 INTRODUÇÃO

Este documento apresenta a primeira etapa do Projeto Aplicado III do curso de Ciência de Dados da Universidade Presbiteriana Mackenzie, cujo tema central é o desenvolvimento de um sistema de recomendação. Nesta etapa são definidos o contexto do trabalho, a motivação, a justificativa, os objetivos, o caráter extensionista da proposta, o conjunto de dados a ser utilizado e a organização inicial do projeto (grupo de trabalho, repositório de materiais e cronograma).

1.1 Contexto do trabalho

Sistemas de recomendação são ferramentas de software que estimam a preferência de um usuário por itens ainda não consumidos e sugerem aqueles com maior probabilidade de interesse (RICCI; ROKACH; SHAPIRA, 2011). Presentes em plataformas de comércio eletrônico, streaming de vídeo e música, redes sociais e catálogos de conteúdo, tais sistemas tornaram-se um dos campos de maior impacto prático da Ciência de Dados, por atuarem diretamente na experiência do usuário e nas métricas de engajamento e retenção das organizações.

As abordagens clássicas dividem-se em filtragem baseada em conteúdo, que recomenda itens semelhantes àqueles que o usuário já avaliou positivamente a partir de seus atributos (gênero, autor, descrição), e filtragem colaborativa, que explora o padrão coletivo de avaliações de muitos usuários para inferir gostos por similaridade entre pessoas ou entre itens, sem depender de atributos descritivos (KOREN; BELL; VOLINSKY, 2009). Modelos híbridos combinam ambas as estratégias para mitigar limitações como o problema da partida a frio (cold start) e a esparsidade das matrizes de interação.

Neste projeto, o domínio de aplicação escolhido é a recomendação de livros. O trabalho dá continuidade à trajetória iniciada no Projeto Aplicado II, no qual foi desenvolvido um pipeline de Processamento de Linguagem Natural para classificação de sentimento em avaliações de filmes e séries, alcançando 88,4% de acurácia com o algoritmo Support Vector Machine. Se naquele projeto o foco foi compreender o que os usuários dizem sobre um conteúdo, o presente trabalho avança para a etapa seguinte da cadeia de valor: a partir das avaliações registradas, prever quais itens cada usuário tende a apreciar e transformar essa previsão em recomendações personalizadas.

1.2 Motivação

A motivação para este trabalho nasce da observação de um contraste. De um lado, grandes plataformas comerciais dispõem de sistemas de recomendação sofisticados, que orientam bilhões de decisões de consumo diariamente. De outro,

equipamentos públicos de cultura e educação, como bibliotecas municipais, comunitárias e escolares, continuam a depender quase exclusivamente da mediação humana e de listas estáticas para aproximar leitores de livros, sem contar com ferramentas que aprendam com o histórico de empréstimos e avaliações de sua comunidade.

A pesquisa Retratos da Leitura no Brasil (INSTITUTO PRÓ-LIVRO, 2020) indica que cerca de metade da população brasileira não é considerada leitora e que a principal barreira apontada pelos entrevistados não é a falta de acesso físico ao livro, mas a dificuldade em encontrar obras que despertem interesse. Esse diagnóstico sugere que o problema central do incentivo à leitura é, em boa medida, um problema de descoberta, exatamente aquele que sistemas de recomendação foram concebidos para resolver.

Do ponto de vista técnico, a motivação está em aprofundar competências em uma classe de algoritmos ainda não explorada no percurso do curso: fatoração de matrizes, vizinhança baseada em usuários e em itens, métricas específicas de ranking (precisão em k , recall em k , NDCG) e o tratamento de matrizes esparsas de grande dimensão. A escolha do domínio de livros, com dados públicos, volumosos e bem estruturados, permite exercitar essas técnicas em condições realistas.

1.3 Justificativa

A justificativa do projeto apoia-se em três dimensões: acadêmica, social e técnica.

Na dimensão acadêmica, o trabalho está plenamente alinhado à ementa do Projeto Aplicado III, centrada em sistemas de recomendação, e permite aplicar de forma integrada conteúdos de álgebra linear, aprendizado de máquina, engenharia de dados e avaliação experimental, consolidando um produto de ciência de dados completo, do dado bruto à recomendação entregue ao usuário final.

Na dimensão social, o projeto propõe uma solução aberta e reutilizável para um problema concreto de instituições públicas que atuam no fomento à leitura. Um recomendador treinado sobre milhões de avaliações reais pode ser adaptado ao acervo de uma biblioteca escolar ou comunitária, oferecendo sugestões personalizadas a estudantes e frequentadores e apoiando o trabalho de bibliotecários e professores na formação de leitores, com impacto direto em metas de educação de qualidade.

Na dimensão técnica, a escolha de um conjunto de dados público, amplamente utilizado como referência (benchmark) em pesquisas de recomendação, garante

reprodutibilidade, comparabilidade dos resultados com a literatura e volume suficiente para que as diferenças entre algoritmos sejam estatisticamente significativas. Além disso, a disponibilidade de metadados dos livros (título, autor, ano, idioma) e de rótulos atribuídos pelos usuários (tags) viabiliza a construção de modelos híbridos, ampliando o escopo do estudo.

1.4 Objetivos

1.4.1 Objetivo geral

Desenvolver e avaliar um sistema de recomendação de livros baseado em filtragem colaborativa, capaz de gerar sugestões personalizadas a partir do histórico de avaliações dos usuários, com vistas à sua aplicação como ferramenta de apoio ao incentivo à leitura em bibliotecas públicas e escolares.

1.4.2 Objetivos específicos

- Realizar a aquisição, a análise exploratória e o tratamento do conjunto de dados goodbooks-10k, caracterizando a distribuição de avaliações, a esparsidade da matriz usuário-item e o comportamento de usuários e livros mais e menos populares.
- Implementar modelos de referência (baseline) não personalizados, como recomendação por popularidade e por média de avaliações, para servirem de piso comparativo.
- Implementar e comparar algoritmos de filtragem colaborativa baseados em vizinhança (k-NN usuário-usuário e item-item) e em fatoração de matrizes (SVD e variantes), utilizando bibliotecas consolidadas do ecossistema Python.
- Construir um modelo híbrido que incorpore os metadados dos livros e as tags atribuídas pelos usuários, avaliando seu efeito sobre a qualidade das recomendações e sobre o problema da partida a frio.
- Avaliar os modelos com métricas de erro de predição (RMSE e MAE) e de qualidade de ranking (precisão em k, recall em k e NDCG em k), adotando protocolo de divisão temporal ou aleatória dos dados em treino e teste.
- Disponibilizar um protótipo funcional que, dado um usuário ou um conjunto de livros lidos, retorne uma lista ordenada de recomendações.
- Documentar integralmente o processo em repositório versionado, garantindo a reprodutibilidade dos experimentos e a reutilização do código por instituições interessadas.

1.5 Objetivo extensionista e alinhamento com os ODS

Além dos objetivos técnicos, este projeto assume um objetivo extensionista, entendido como a devolução à sociedade de um resultado concreto do conhecimento produzido na universidade. A proposta é que o sistema de recomendação desenvolvido seja disponibilizado como solução de código aberto, acompanhada de documentação acessível, de modo que possa ser adaptada por bibliotecas escolares, comunitárias e municipais, inclusive as da rede pública de Guarulhos, cidade onde o projeto é desenvolvido, para sugerir leituras personalizadas a seus frequentadores e apoiar bibliotecários e educadores em programas de formação de leitores.

Essa finalidade está alinhada aos Objetivos de Desenvolvimento Sustentável da Agenda 2030 da Organização das Nações Unidas (ONU, 2015), em especial:

- **ODS 4 – Educação de qualidade:** a meta 4.6 busca garantir que jovens e adultos alcancem a alfabetização plena, e a meta 4.7 visa assegurar a aquisição de conhecimentos e habilidades para o desenvolvimento sustentável. O incentivo ao hábito de leitura, por meio de recomendações que aumentem a chance de o leitor encontrar obras de seu interesse, contribui diretamente para essas metas.
- **ODS 10 – Redução das desigualdades:** ao levar a equipamentos públicos uma tecnologia hoje restrita a grandes plataformas comerciais, o projeto amplia o acesso de populações de menor renda a ferramentas de descoberta cultural, reduzindo assimetrias de acesso à informação e à cultura.
- **ODS 9 – Indústria, inovação e infraestrutura:** a disponibilização de um artefato aberto e reproduzível fortalece a infraestrutura tecnológica de instituições públicas e estimula a inovação de base comunitária.

Como entrega extensionista, prevê-se ao final do projeto a publicação do código, de um guia de implantação e de um relatório de resultados em linguagem acessível, dirigidos a gestores de bibliotecas e educadores.

1.6 Apresentação do conjunto de dados

O conjunto de dados selecionado é o goodbooks-10k (ZAJAC, 2017), base pública e amplamente utilizada como referência em estudos de sistemas de recomendação. Ele reúne avaliações explícitas de usuários da plataforma Goodreads sobre os dez mil livros mais avaliados do site, além de metadados e rótulos atribuídos pelos próprios leitores. Trata-se, portanto, de um dataset construído especificamente para o problema de recomendação, contendo a tríade essencial usuário–item–

avaliação em volume suficiente para o treinamento e a comparação robusta de modelos.

A base é composta por cinco arquivos no formato CSV, resumidos no Quadro 1.

Quadro 1 – Estrutura do conjunto de dados goodbooks-10k

Arquivo	Dimensão aproximada	Principais colunas
ratings.csv	5.976.479 linhas × 3 colunas	user_id, book_id, rating (escala de 1 a 5)
books.csv	10.000 linhas × 23 colunas	book_id, goodreads_book_id, authors, original_publication_year, original_title, title, language_code, average_rating, ratings_count, ratings_1 a ratings_5, image_url
to_read.csv	912.705 linhas × 2 colunas	user_id, book_id (livros marcados como "quero ler", sinal implícito de interesse)
tags.csv	34.252 linhas × 2 colunas	tag_id, tag_name
book_tags.csv	999.912 linhas × 3 colunas	goodreads_book_id, tag_id, count (frequência com que cada tag foi atribuída ao livro)

Fonte: elaborado pelo autor a partir de Zajac (2017).

Em síntese, a base contempla cerca de 6 milhões de avaliações explícitas, realizadas por 53.424 usuários sobre 10.000 livros, sendo que cada usuário possui no mínimo duas avaliações e cada livro recebeu pelo menos cem avaliações. A matriz usuário-item resultante tem esparsidade superior a 98%, característica típica de problemas reais de recomendação e que exige o emprego de técnicas adequadas de fatoração e de armazenamento esparsos.

A presença simultânea de avaliações explícitas (ratings), sinais implícitos (to_read), metadados descritivos (books) e rótulos gerados pela comunidade (tags e book_tags) torna o conjunto adequado a todas as abordagens previstas nos objetivos específicos: filtragem colaborativa, filtragem baseada em conteúdo e modelos híbridos. O dataset é distribuído sob licença aberta e pode ser obtido no repositório público do autor original no GitHub, o que assegura reprodutibilidade e ausência de restrições de uso para fins acadêmicos.

1.7 Organização do projeto

1.7.1 Grupo de trabalho

O projeto será desenvolvido individualmente pelo aluno Enzo Enrico Braga Cavalcante (RA 10744145), responsável por todas as frentes: aquisição e tratamento

dos dados, análise exploratória, implementação e avaliação dos modelos, construção do protótipo, documentação e elaboração dos relatórios e da apresentação final.

1.7.2 Repositório de materiais

Todo o material do projeto (código-fonte, notebooks, scripts de tratamento de dados, documentação e relatórios de cada etapa) será organizado e versionado em repositório público no GitHub, seguindo a estrutura de pastas abaixo:

- **data/** – scripts de download e amostras dos dados brutos e tratados;
- **notebooks/** – análise exploratória e experimentos de modelagem;
- **src/** – módulos Python reutilizáveis (pré-processamento, modelos, avaliação);
- **docs/** – relatórios das etapas, apresentação e guia de implantação;
- **README.md** – descrição do projeto, instruções de execução e resultados.

Endereço do repositório: <https://github.com/Enzo-Enrico/Projeto-Aplicado-III-Sistema-Recomendacao>

1.7.3 Cronograma

O Quadro 2 apresenta o planejamento das atividades ao longo das quatro etapas previstas para a disciplina.

Quadro 2 – Cronograma do projeto

Etapas	Atividades	Período previsto
1	Definição do tema, organização do grupo, criação do repositório, elaboração da Capa, Sumário e Introdução.	Setembro/2026
2	Aquisição dos dados, análise exploratória, tratamento e construção da matriz usuário-item; elaboração do Referencial Teórico e da Metodologia.	Setembro a Outubro/2026
3	Implementação dos baselines, dos modelos de filtragem colaborativa e do modelo híbrido; avaliação com métricas de erro e de ranking; redação dos Resultados preliminares.	Outubro a Novembro/2026
4	Refinamento dos modelos, construção do protótipo de recomendação, elaboração do guia de implantação (entrega extensionista), Resumo, Conclusão, relatório final e apresentação.	Novembro a Dezembro/2026

Fonte: elaborado pelo autor.

REFERÊNCIAS

INSTITUTO PRÓ-LIVRO. **Retratos da Leitura no Brasil**. 5. ed. São Paulo: Instituto Pró-Livro; Itaú Cultural, 2020.

KOREN, Yehuda; BELL, Robert; VOLINSKY, Chris. Matrix factorization techniques for recommender systems. **Computer**, v. 42, n. 8, p. 30-37, 2009.

ORGANIZAÇÃO DAS NAÇÕES UNIDAS. **Transformando nosso mundo: a Agenda 2030 para o Desenvolvimento Sustentável**. Nova York: ONU, 2015.

RICCI, Francesco; ROKACH, Lior; SHAPIRA, Bracha. Introduction to recommender systems handbook. In: RICCI, F.; ROKACH, L.; SHAPIRA, B.; KANTOR, P. B. (ed.). **Recommender Systems Handbook**. Boston: Springer, 2011. p. 1-35.

ZAJAC, Zygmunt. **goodbooks-10k: a new dataset for book recommendations**. FastML, 2017. Disponível em: <https://github.com/zygmuntz/goodbooks-10k>. Acesso em: 4 set. 2026.