

UNIVERSIDADE PRESBITERIANA MACKENZIE

Faculdade de Computação e Informática

Curso de Ciência de Dados

ENZO ENRICO BRAGA CAVALCANTE

RA: 10744145

PROJETO APLICADO III

**SISTEMA DE RECOMENDAÇÃO DE LIVROS BASEADO EM
FILTRAGEM COLABORATIVA:
uma aplicação para o incentivo à leitura em bibliotecas públicas e
escolares**

Etapa 2 – Introdução e Referencial Teórico

Guarulhos

2026

SUMÁRIO

1 INTRODUÇÃO.....	3
1.1 Contexto do trabalho.....	3
1.2 Motivação.....	4
1.3 Justificativa.....	4
1.4 Objetivos.....	5
1.4.1 Objetivo geral.....	5
1.4.2 Objetivos específicos.....	5
1.5 Objetivo extensionista e alinhamento com os ODS.....	6
1.6 Apresentação do conjunto de dados.....	7
1.7 Organização do projeto.....	8
1.7.1 Grupo de trabalho.....	8
1.7.2 Repositório de materiais.....	8
1.7.3 Cronograma.....	8
2 REFERENCIAL TEÓRICO.....	10
2.1 Sistemas de recomendação: conceitos e taxonomia.....	10
2.2 Filtragem colaborativa baseada em vizinhança.....	11
2.3 Fatoração de matrizes e modelos de fatores latentes.....	11
2.4 Aprendizado profundo e o debate sobre progresso na área.....	12
2.5 Avaliação de sistemas de recomendação: predição de nota versus qualidade do ranking.....	13
2.6 Recomendação de livros e trabalhos relacionados.....	14
2.7 Ferramentas computacionais.....	15
2.8 Síntese e posicionamento do trabalho.....	15
REFERÊNCIAS.....	18

1 INTRODUÇÃO

Este documento apresenta o Projeto Aplicado III do curso de Ciência de Dados da Universidade Presbiteriana Mackenzie, cujo tema central é o desenvolvimento de um sistema de recomendação. Esta introdução define o contexto do trabalho, a motivação, a justificativa, os objetivos, o caráter extensionista da proposta, o conjunto de dados utilizado e a organização do projeto (grupo de trabalho, repositório de materiais e cronograma). O Capítulo 2 apresenta o referencial teórico que fundamenta as escolhas técnicas do projeto e o posiciona na área de pesquisa de sistemas de recomendação. Nesta segunda versão, o escopo dos objetivos específicos foi ajustado a partir da orientação docente recebida na primeira etapa, priorizando um número menor de modelos com avaliação experimental sólida e colocando as métricas de ranking no centro da comparação entre eles.

1.1 Contexto do trabalho

Sistemas de recomendação são ferramentas de software que estimam a preferência de um usuário por itens ainda não consumidos e sugerem aqueles com maior probabilidade de interesse (RICCI; ROKACH; SHAPIRA, 2022). Presentes em plataformas de comércio eletrônico, streaming de vídeo e música, redes sociais e catálogos de conteúdo, tais sistemas tornaram-se um dos campos de maior impacto prático da Ciência de Dados, por atuarem diretamente na experiência do usuário e nas métricas de engajamento e retenção das organizações.

As abordagens clássicas dividem-se em filtragem baseada em conteúdo, que recomenda itens semelhantes àqueles que o usuário já avaliou positivamente a partir de seus atributos (gênero, autor, descrição), e filtragem colaborativa, que explora o padrão coletivo de avaliações de muitos usuários para inferir gostos por similaridade entre pessoas ou entre itens, sem depender de atributos descritivos (KOREN; BELL; VOLINSKY, 2009). Modelos híbridos combinam ambas as estratégias para mitigar limitações como o problema da partida a frio (cold start) e a esparsidade das matrizes de interação.

Neste projeto, o domínio de aplicação escolhido é a recomendação de livros. O trabalho dá continuidade à trajetória iniciada no Projeto Aplicado II, no qual foi desenvolvido um pipeline de Processamento de Linguagem Natural para classificação de sentimento em avaliações de filmes e séries, alcançando 88,4% de acurácia com o algoritmo Support Vector Machine. Se naquele projeto o foco foi compreender o que os usuários dizem sobre um conteúdo, o presente trabalho avança para a etapa seguinte da cadeia de valor: a partir das avaliações registradas, prever quais itens cada usuário tende a apreciar e transformar essa previsão em recomendações personalizadas.

1.2 Motivação

A motivação para este trabalho nasce da observação de um contraste. De um lado, grandes plataformas comerciais dispõem de sistemas de recomendação sofisticados, que orientam bilhões de decisões de consumo diariamente. De outro, equipamentos públicos de cultura e educação, como bibliotecas municipais, comunitárias e escolares, continuam a depender quase exclusivamente da mediação humana e de listas estáticas para aproximar leitores de livros, sem contar com ferramentas que aprendam com o histórico de empréstimos e avaliações de sua comunidade.

A pesquisa Retratos da Leitura no Brasil (INSTITUTO PRÓ-LIVRO, 2020) indica que cerca de metade da população brasileira não é considerada leitora e que a principal barreira apontada pelos entrevistados não é a falta de acesso físico ao livro, mas a dificuldade em encontrar obras que despertem interesse. Esse diagnóstico sugere que o problema central do incentivo à leitura é, em boa medida, um problema de descoberta, exatamente aquele que sistemas de recomendação foram concebidos para resolver.

Do ponto de vista técnico, a motivação está em aprofundar competências em uma classe de algoritmos ainda não explorada no percurso do curso: fatoração de matrizes, vizinhança baseada em itens, métricas específicas de ranking (precisão em k , recall em k , NDCG) e o tratamento de matrizes esparsas de grande dimensão. A escolha do domínio de livros, com dados públicos, volumosos e bem estruturados, permite exercitar essas técnicas em condições realistas.

1.3 Justificativa

A justificativa do projeto apoia-se em três dimensões: acadêmica, social e técnica.

Na dimensão acadêmica, o trabalho está plenamente alinhado à ementa do Projeto Aplicado III, centrada em sistemas de recomendação, e permite aplicar de forma integrada conteúdos de álgebra linear, aprendizado de máquina, engenharia de dados e avaliação experimental, consolidando um produto de ciência de dados completo, do dado bruto à recomendação entregue ao usuário final.

Na dimensão social, o projeto propõe uma solução aberta e reutilizável para um problema concreto de instituições públicas que atuam no fomento à leitura. Um recomendador treinado sobre milhões de avaliações reais pode ser adaptado ao acervo de uma biblioteca escolar ou comunitária, oferecendo sugestões personalizadas a estudantes e frequentadores e apoiando o trabalho de bibliotecários

e professores na formação de leitores, com impacto direto em metas de educação de qualidade.

Na dimensão técnica, a escolha de um conjunto de dados público, amplamente utilizado como referência (benchmark) em pesquisas de recomendação, garante reprodutibilidade, comparabilidade dos resultados com a literatura e volume suficiente para que as diferenças entre algoritmos sejam estatisticamente significativas. Além disso, a disponibilidade de metadados dos livros (título, autor, ano, idioma) e de rótulos atribuídos pelos usuários (tags) deixa aberta a possibilidade de extensões híbridas.

1.4 Objetivos

1.4.1 Objetivo geral

Desenvolver e avaliar um sistema de recomendação de livros baseado em filtragem colaborativa, capaz de gerar listas personalizadas de sugestões a partir do histórico de avaliações dos usuários, com vistas à sua aplicação como ferramenta de apoio ao incentivo à leitura em bibliotecas públicas e escolares.

1.4.2 Objetivos específicos

- Realizar a aquisição, a análise exploratória e o tratamento do conjunto de dados goodbooks-10k, caracterizando a distribuição de avaliações, a esparsidade da matriz usuário-item e o comportamento de cauda longa de usuários e livros.
- Implementar modelos de referência (baseline) não personalizados, como recomendação por popularidade e por média de avaliações, para servirem de piso comparativo.
- Implementar e comparar um conjunto enxuto de algoritmos de filtragem colaborativa: vizinhança item-item (k-NN) e fatoração de matrizes em suas variantes voltadas à predição de nota (SVD com vieses) e à geração de ranking (PureSVD e ALS para feedback implícito).
- Separar explicitamente dois tipos de avaliação: erro de predição de nota (RMSE e MAE) e qualidade da lista recomendada (Precision@k, Recall@k e NDCG@k), adotando as métricas de ranking como critério central para a escolha do modelo, por ser a lista de livros o produto final do sistema.
- Conduzir uma avaliação experimental rigorosa, com protocolo de divisão treino/teste por usuário, ranking completo sobre todos os itens não vistos e ajuste de hiperparâmetros dos modelos selecionados.

- Disponibilizar um protótipo funcional que, dado um usuário ou um conjunto de livros lidos, retorne uma lista ordenada de recomendações.
- Documentar integralmente o processo em repositório versionado, garantindo a reprodutibilidade dos experimentos e a reutilização do código por instituições interessadas.

Modelos híbridos com metadados e tags, bem como o tratamento específico do problema da partida a frio, passam a ser considerados extensões condicionais, a serem desenvolvidas somente se o cronograma permitir após a consolidação da avaliação experimental dos modelos principais.

1.5 Objetivo extensionista e alinhamento com os ODS

Além dos objetivos técnicos, este projeto assume um objetivo extensionista, entendido como a devolução à sociedade de um resultado concreto do conhecimento produzido na universidade. A proposta é que o sistema de recomendação desenvolvido seja disponibilizado como solução de código aberto, acompanhada de documentação acessível, de modo que possa ser adaptada por bibliotecas escolares, comunitárias e municipais, inclusive as da rede pública de Guarulhos, cidade onde o projeto é desenvolvido, para sugerir leituras personalizadas a seus frequentadores e apoiar bibliotecários e educadores em programas de formação de leitores.

Essa finalidade está alinhada aos Objetivos de Desenvolvimento Sustentável da Agenda 2030 da Organização das Nações Unidas (ONU, 2015), em especial:

- **ODS 4 – Educação de qualidade:** a meta 4.6 busca garantir que jovens e adultos alcancem a alfabetização plena, e a meta 4.7 visa assegurar a aquisição de conhecimentos e habilidades para o desenvolvimento sustentável. O incentivo ao hábito de leitura, por meio de recomendações que aumentem a chance de o leitor encontrar obras de seu interesse, contribui diretamente para essas metas.
- **ODS 10 – Redução das desigualdades:** ao levar a equipamentos públicos uma tecnologia hoje restrita a grandes plataformas comerciais, o projeto amplia o acesso de populações de menor renda a ferramentas de descoberta cultural, reduzindo assimetrias de acesso à informação e à cultura.
- **ODS 9 – Indústria, inovação e infraestrutura:** a disponibilização de um artefato aberto e reprodutível fortalece a infraestrutura tecnológica de instituições públicas e estimula a inovação de base comunitária.

Como entrega extensionista, prevê-se ao final do projeto a publicação do código, de um guia de implantação e de um relatório de resultados em linguagem acessível, dirigidos a gestores de bibliotecas e educadores.

1.6 Apresentação do conjunto de dados

O conjunto de dados selecionado é o goodbooks-10k (ZAJAC, 2017), base pública e amplamente utilizada como referência em estudos de sistemas de recomendação. Ele reúne avaliações explícitas de usuários da plataforma Goodreads sobre os dez mil livros mais avaliados do site, além de metadados e rótulos atribuídos pelos próprios leitores. Trata-se, portanto, de um dataset construído especificamente para o problema de recomendação, contendo a tríade essencial usuário–item–avaliação em volume suficiente para o treinamento e a comparação robusta de modelos.

A base é composta por cinco arquivos no formato CSV, resumidos no Quadro 1.

Quadro 1 – Estrutura do conjunto de dados goodbooks-10k

Arquivo	Dimensão	Principais colunas
ratings.csv	5.976.479 linhas × 3 colunas	user_id, book_id, rating (escala de 1 a 5)
books.csv	10.000 linhas × 23 colunas	book_id, goodreads_book_id, authors, original_publication_year, original_title, title, language_code, average_rating, ratings_count, ratings_1 a ratings_5, image_url
to_read.csv	912.705 linhas × 2 colunas	user_id, book_id (livros marcados como "quero ler", sinal implícito de interesse)
tags.csv	34.252 linhas × 2 colunas	tag_id, tag_name
book_tags.csv	999.912 linhas × 3 colunas	goodreads_book_id, tag_id, count (frequência com que cada tag foi atribuída ao livro)

Fonte: elaborado pelo autor a partir de Zajac (2017).

Em síntese, a base contempla cerca de 6 milhões de avaliações explícitas, realizadas por 53.424 usuários sobre 10.000 livros, sendo que cada usuário possui entre 19 e 200 avaliações (mediana de 111) e cada livro recebeu entre 8 e 22.806 avaliações (mediana de 248). A matriz usuário-item resultante tem esparsidade de 98,9%, característica típica de problemas reais de recomendação e que exige o emprego de técnicas adequadas de fatoração e de armazenamento esparsos.

A presença simultânea de avaliações explícitas (ratings), sinais implícitos (to_read), metadados descritivos (books) e rótulos gerados pela comunidade (tags e

book_tags) torna o conjunto adequado às abordagens previstas nos objetivos específicos (filtragem colaborativa por vizinhança e por fatoração, com feedback explícito e implícito) e às extensões híbridas eventualmente exploradas. O dataset é distribuído sob licença aberta e pode ser obtido no repositório público do autor original no GitHub, o que assegura reprodutibilidade e ausência de restrições de uso para fins acadêmicos.

1.7 Organização do projeto

1.7.1 Grupo de trabalho

O projeto é desenvolvido individualmente pelo aluno Enzo Enrico Braga Cavalcante (RA 10744145), responsável por todas as frentes: aquisição e tratamento dos dados, análise exploratória, implementação e avaliação dos modelos, construção do protótipo, documentação e elaboração dos relatórios e da apresentação final.

1.7.2 Repositório de materiais

Todo o material do projeto (código-fonte, notebooks, scripts de tratamento de dados, documentação e relatórios de cada etapa) é organizado e versionado em repositório público no GitHub, seguindo a estrutura de pastas abaixo:

- **data/** – scripts de download e amostras dos dados brutos e tratados;
- **notebooks/** – análise exploratória e experimentos de modelagem;
- **src/** – módulos Python reutilizáveis (pré-processamento, modelos, avaliação);
- **docs/** – relatórios das etapas, apresentação e guia de implantação;
- **README.md** – descrição do projeto, instruções de execução e resultados.

Endereço do repositório: <https://github.com/Enzo-Enrico/Projeto-Aplicado-III-Sistema-Recomendacao>

1.7.3 Cronograma

O Quadro 2 apresenta o planejamento das atividades ao longo das quatro etapas previstas para a disciplina, com o status atual de cada uma.

Quadro 2 – Cronograma do projeto

Etapa	Atividades	Período	Status
1	Definição do tema, organização do grupo, criação do repositório, elaboração da Capa, Sumário e Introdução.	Set/2026	Concluída
2	Definição das bibliotecas Python, análise exploratória, tratamento dos dados, definição da técnica, treinamento	Set–Out/2026	Concluída

Etapas	Atividades	Período	Status
	de modelo inicial (prova de conceito), definição da forma de avaliação e elaboração do Referencial Teórico.		
3	Ajuste de hiperparâmetros dos modelos selecionados, avaliação experimental completa (erro de predição e ranking), redação da Metodologia e dos Resultados.	Out–Nov/2026	Em andamento
4	Refinamento, protótipo de recomendação, guia de implantação (entrega extensionista), Resumo, Conclusão, relatório e apresentação final.	Nov–Dez/2026	Prevista

Fonte: elaborado pelo autor.

2 REFERENCIAL TEÓRICO

Este capítulo apresenta a revisão da literatura que fundamenta o projeto. Inicia-se pela definição e taxonomia dos sistemas de recomendação; em seguida, aprofundam-se as duas famílias de filtragem colaborativa adotadas no trabalho (vizinhança e fatores latentes), o debate recente sobre o real progresso trazido por modelos neurais, as formas de avaliação de recomendadores (com ênfase na distinção entre erro de predição e qualidade de ranking), os trabalhos relacionados à recomendação de livros e as ferramentas computacionais empregadas. O capítulo encerra-se com uma síntese dos estudos revisados e o posicionamento do sistema proposto na área.

2.1 Sistemas de recomendação: conceitos e taxonomia

Adomavicius e Tuzhilin (2005), em levantamento que se tornou referência fundadora da área, formalizam o problema de recomendação como a estimativa de uma função de utilidade $u: \text{Usuários} \times \text{Itens} \rightarrow \mathbb{R}$, conhecida apenas para um subconjunto esparsos de pares (usuário, item), e cuja extrapolação para os pares desconhecidos permite selecionar, para cada usuário, os itens de maior utilidade estimada. Os autores classificam as abordagens em três grupos: baseadas em conteúdo, nas quais a utilidade é estimada a partir da semelhança entre os atributos dos itens e o perfil do usuário; colaborativas, nas quais a estimativa decorre das utilidades atribuídas por usuários com gostos semelhantes; e híbridas, que combinam as duas estratégias.

Ricci, Rokach e Shapira (2022), na terceira edição do Recommender Systems Handbook, consolidam a área como campo interdisciplinar que conjuga recuperação de informação, aprendizado de máquina, interação humano-computador e ciências do comportamento, e situam a função dos recomendadores em dois níveis: para o usuário, reduzir a sobrecarga de informação e apoiar a descoberta; para o provedor, aumentar engajamento, diversidade de consumo e fidelização. Aggarwal (2016) complementa essa visão com um tratamento sistemático dos modelos, distinguindo ainda os tipos de retroalimentação: explícita, quando o usuário atribui notas ou avaliações; e implícita, quando a preferência é inferida de ações como compras, cliques, empréstimos ou marcações de interesse.

Essa taxonomia é diretamente aplicável ao presente projeto. O conjunto goodbooks-10k fornece retroalimentação explícita (notas de 1 a 5) e implícita (marcações "quero ler"), e a abordagem adotada é a filtragem colaborativa, por ser aquela que, segundo a literatura, obtém os melhores resultados quando há volume

suficiente de interações e que não depende da qualidade de descrições textuais dos itens, frequentemente ausentes ou heterogêneas em acervos de bibliotecas públicas.

2.2 Filtragem colaborativa baseada em vizinhança

Os métodos baseados em vizinhança constituem a abordagem mais antiga e intuitiva da filtragem colaborativa. Herlocker et al. (1999) estruturam o arcabouço algorítmico da variante usuário-usuário: identificam-se, para o usuário-alvo, os k usuários mais semelhantes segundo uma medida como a correlação de Pearson, e a nota de um item desconhecido é estimada pela média ponderada das notas desses vizinhos, corrigida pelas médias individuais para compensar vieses de escala. Os autores demonstram a importância de ajustes como a penalização de similaridades computadas sobre poucos itens em comum.

Sarwar et al. (2001) propõem a variante item-item, na qual a similaridade é calculada entre itens, a partir dos vetores de notas que receberam, e a nota prevista para um par (usuário, item) é a média ponderada das notas que o próprio usuário atribuiu aos itens mais semelhantes. Os autores mostram que, além de produzir qualidade igual ou superior à abordagem usuário-usuário, o modelo item-item é computacionalmente mais vantajoso em cenários típicos, em que o número de usuários supera largamente o de itens e as similaridades entre itens são mais estáveis no tempo, podendo ser pré-computadas. Ning, Desrosiers e Karypis (2015) apresentam uma revisão abrangente desses métodos, discutindo medidas de similaridade (cosseno, cosseno ajustado, Pearson), normalização de notas, seleção de vizinhos e sua interpretabilidade, característica valiosa para justificar recomendações ao usuário final ("recomendado porque você gostou de X").

No presente projeto, adota-se o modelo item-item com similaridade do cosseno sobre notas centradas na média de cada item, com restrição aos k vizinhos mais próximos. A escolha se apoia nos argumentos de eficiência e estabilidade de Sarwar et al. (2001), especialmente adequados ao goodbooks-10k, que possui cinco vezes mais usuários do que livros, e na interpretabilidade apontada por Ning, Desrosiers e Karypis (2015), relevante para o uso por bibliotecários e leitores.

2.3 Fatoração de matrizes e modelos de fatores latentes

A segunda família adotada é a dos modelos de fatores latentes, popularizados pelo Netflix Prize. Koren, Bell e Volinsky (2009) descrevem a fatoração de matrizes como a representação de usuários e itens em um mesmo espaço de dimensão reduzida, de modo que a nota prevista seja o produto interno entre o vetor do usuário e o vetor do item, acrescido de vieses globais, de usuário e de item. Os parâmetros são

aprendidos pela minimização do erro quadrático regularizado sobre as notas observadas, por gradiente estocástico ou por mínimos quadrados alternados (ALS). Koren (2008) estende o modelo ao integrar informação de vizinhança e feedback implícito (SVD++), obtendo ganhos adicionais de precisão.

Para cenários de retroalimentação implícita, Hu, Koren e Volinsky (2008) propõem uma formulação distinta: todas as interações ausentes são tratadas como preferência negativa fraca, e cada observação recebe um nível de confiança proporcional à intensidade da interação; o problema resultante é resolvido eficientemente por ALS com truques algébricos que evitam o custo quadrático no número de itens. Rendle et al. (2009) seguem outra via, formulando a aprendizagem diretamente como um problema de ordenação por pares (BPR), em que o modelo é otimizado para pontuar itens consumidos acima dos não consumidos.

Cremonesi, Koren e Turrin (2010) apresentam um resultado de grande relevância para este projeto. Ao avaliar algoritmos em tarefas de recomendação top-N, em vez de predição de nota, os autores observam que modelos otimizados para minimizar o erro de predição não são necessariamente os melhores para gerar listas, e que uma técnica simples, o PureSVD, consistindo na decomposição em valores singulares truncada da matriz usuário-item preenchida com zeros, supera modelos mais sofisticados em métricas de ranking. O trabalho evidencia que a escolha do objetivo de treinamento deve refletir a tarefa final do sistema.

Com base nessa literatura, o projeto compara três variantes de fatoração: o SVD com vieses de Koren, Bell e Volinsky (2009), treinado para predição de nota; o PureSVD de Cremonesi, Koren e Turrin (2010), voltado a ranking; e o ALS para feedback implícito de Hu, Koren e Volinsky (2008), que explora o fato de que a mera presença de uma avaliação já é um sinal de interesse pelo livro.

2.4 Aprendizado profundo e o debate sobre progresso na área

A partir de 2016, modelos baseados em redes neurais passaram a dominar a produção acadêmica em recomendação. He et al. (2017) propõem o Neural Collaborative Filtering (NCF), que substitui o produto interno da fatoração de matrizes por um perceptron multicamadas, argumentando que a não linearidade permite capturar interações mais complexas entre usuários e itens.

Esse entusiasmo, porém, foi objeto de escrutínio rigoroso. Ferrari Dacrema, Cremonesi e Jannach (2019) reproduziram dezoito métodos neurais publicados em conferências de primeira linha e constataram que apenas sete eram reproduzíveis com esforço razoável e que, destes, seis eram superados por baselines simples, como

vizinhança e fatoração linear, quando estes eram adequadamente ajustados. A versão estendida do estudo (FERRARI DACREMA et al., 2021) confirma o diagnóstico e atribui o fenômeno a baselines fracos, ajuste insuficiente de hiperparâmetros e protocolos de avaliação inconsistentes. Na mesma direção, Rendle et al. (2020) demonstram que a fatoração de matrizes com produto interno, quando bem ajustada, supera o NCF nos próprios conjuntos de dados em que este fora proposto, e que o produto interno é, além disso, muito mais eficiente para a recuperação dos top-N itens em produção.

Esses estudos recentes sustentam diretamente a decisão metodológica deste projeto, alinhada à orientação docente, de concentrar o esforço em poucos modelos clássicos com avaliação experimental rigorosa e ajuste cuidadoso de hiperparâmetros, em vez de implementar superficialmente um número maior de técnicas. A literatura indica que baselines bem calibrados constituem, hoje, o padrão de comparação mais confiável da área.

2.5 Avaliação de sistemas de recomendação: predição de nota versus qualidade do ranking

Herlocker et al. (2004) oferecem a primeira sistematização ampla da avaliação de recomendadores colaborativos, distinguindo as tarefas que o usuário realiza (encontrar bons itens, avaliar todos os itens, receber uma sequência de recomendações) e argumentando que a métrica deve corresponder à tarefa. Os autores agrupam as métricas em três classes: acurácia de predição (erro entre a nota prevista e a observada, como MAE e RMSE), acurácia de classificação (capacidade de separar itens relevantes de irrelevantes, como precisão e revocação) e acurácia de ordenação (qualidade da ordem da lista). Shani e Gunawardana (2011) atualizam essa discussão, acrescentando propriedades como cobertura, novidade, diversidade e serendipidade, e detalham os protocolos de avaliação offline, online e por estudos de usuários.

A diferença entre erro de predição e qualidade de ranking é central. RMSE e MAE medem quão próxima a nota prevista está da nota real, mas apenas sobre os itens que o usuário efetivamente avaliou; já as métricas de ranking medem se os itens relevantes aparecem no topo de uma lista construída entre todos os itens candidatos. Cremonesi, Koren e Turrin (2010) demonstram empiricamente que as duas famílias podem produzir ordenações distintas dos algoritmos, e que a predição de nota tende a favorecer itens de nicho com notas altas, mas pouco prováveis de serem consumidos. Para a tarefa de ordenação, Järvelin e Kekäläinen (2002) introduzem o ganho cumulativo descontado (DCG) e sua versão normalizada (NDCG), que premiam a

presença de itens relevantes nas primeiras posições com desconto logarítmico, tornando-se a métrica padrão de ranking em recuperação de informação e recomendação.

Trabalhos recentes refinam o protocolo experimental. Krichene e Rendle (2020) mostram que avaliar o ranking sobre uma amostra de itens negativos, prática comum para reduzir custo computacional, produz métricas inconsistentes com as calculadas sobre o conjunto completo de itens, podendo inverter a ordem relativa dos modelos; recomendam, portanto, o ranking exaustivo sempre que viável. Meng et al. (2020) demonstram que a estratégia de divisão dos dados em treino e teste (aleatória, temporal, por usuário) altera substancialmente os resultados e a classificação dos algoritmos, exigindo que o protocolo seja explicitado. Castells e Moffat (2022) revisam os desafios da avaliação offline, como vieses de popularidade e de exposição, e defendem a definição clara da tarefa que o sistema deve cumprir como ponto de partida de qualquer avaliação.

O projeto incorpora esses aprendizados: as avaliações de erro de predição (RMSE e MAE) e de qualidade da lista (Precision@k, Recall@k e NDCG@k) são reportadas separadamente; o ranking é calculado de forma exaustiva sobre todos os itens não vistos pelo usuário, conforme Krichene e Rendle (2020); o protocolo de divisão por usuário é explicitado, conforme Meng et al. (2020); e, como o produto final é uma lista de livros, as métricas de ranking são o critério decisivo na escolha do modelo, em consonância com Herlocker et al. (2004) e Cremonesi, Koren e Turrin (2010).

2.6 Recomendação de livros e trabalhos relacionados

O domínio de livros possui tradição própria na literatura de recomendação. Ziegler et al. (2005) coletaram o conjunto Book-Crossing, com mais de um milhão de avaliações de livros, e o utilizaram para propor a diversificação por tópicos de listas de recomendação, mostrando, por meio de estudo com usuários, que listas ligeiramente menos precisas, porém mais diversas, são percebidas como mais satisfatórias. O resultado é especialmente relevante para o contexto de incentivo à leitura, em que ampliar o repertório do leitor é tão importante quanto acertar o gosto já conhecido.

Wan e McAuley (2018) coletaram um conjunto de dados em larga escala da plataforma Goodreads, a mesma origem do goodbooks-10k, e modelaram o comportamento do leitor como uma cadeia monotônica de interações (adicionar à estante, ler, avaliar, recomendar), demonstrando que sinais implícitos mais fracos, como marcar um livro como "quero ler", carregam informação útil para prever

interações mais fortes. Esse achado fundamenta o uso do arquivo `to_read` como fonte complementar de retroalimentação implícita no presente projeto.

O `goodbooks-10k`, disponibilizado por Zajac (2017), foi construído justamente para suprir a carência de um conjunto de dados de livros moderno, denso e com metadados, comparável ao `MovieLens` no domínio de filmes. Sua ampla adoção em tutoriais, cursos e artigos de benchmark o torna adequado para comparar os resultados aqui obtidos com os da comunidade. Para a extensão híbrida eventual, Kula (2015) propõe o modelo `LightFM`, que representa usuários e itens como somas de embeddings de seus metadados, permitindo recomendar itens novos a partir de tags e atributos, estratégia diretamente aplicável às tags do `goodbooks-10k` para mitigar a partida a frio, problema caracterizado por Schein et al. (2002).

2.7 Ferramentas computacionais

A implementação utiliza o ecossistema científico da linguagem Python. A biblioteca `pandas` (McKINNEY, 2010) é empregada para carga, limpeza e análise exploratória dos arquivos CSV; `NumPy` (HARRIS et al., 2020) e `SciPy` (VIRTANEN et al., 2020) fornecem as estruturas de matrizes esparsas, a decomposição em valores singulares truncada e as operações vetorizadas necessárias ao cálculo de similaridades e de rankings exaustivos; e `scikit-learn` (PEDREGOSA et al., 2011) oferece utilitários de normalização e de divisão de dados.

Para os modelos de recomendação propriamente ditos, são adotadas duas bibliotecas especializadas. `Surprise` (HUG, 2020) implementa os algoritmos clássicos de predição de nota, incluindo o SVD com vieses treinado por gradiente estocástico, com validação cruzada e busca de hiperparâmetros integradas. `Implicit` (FREDERICKSON, 2016) implementa, de forma otimizada, o ALS para feedback implícito de Hu, Koren e Volinsky (2008) e o BPR de Rendle et al. (2009). As métricas de ranking são implementadas pelo autor sobre `NumPy`, de modo a garantir o protocolo exaustivo recomendado por Krichene e Rendle (2020) e a total transparência do cálculo. A visualização utiliza `Matplotlib`.

2.8 Síntese e posicionamento do trabalho

O Quadro 3 sintetiza os principais trabalhos revisados e a contribuição de cada um para as decisões deste projeto.

Quadro 3 – Síntese dos trabalhos revisados e sua contribuição ao projeto

Trabalho	Tema	Contribuição ao projeto
Adomavicius e Tuzhilin (2005); Ricci, Rokach e Shapira (2022);	Fundamentos e taxonomia	Formalização do problema; escolha da filtragem colaborativa; distinção entre

Trabalho	Tema	Contribuição ao projeto
Aggarwal (2016)		feedback explícito e implícito.
Herlocker et al. (1999); Sarwar et al. (2001); Ning, Desrosiers e Karypis (2015)	Vizinhança	Adoção do modelo item-item com cosseno e k vizinhos; interpretabilidade das recomendações.
Koren, Bell e Volinsky (2009); Koren (2008); Hu, Koren e Volinsky (2008); Rendle et al. (2009)	Fatores latentes	Escolha do SVD com vieses e do ALS implícito como modelos de fatoração.
Cremonesi, Koren e Turrin (2010)	Top-N e PureSVD	Inclusão do PureSVD; evidência de que erro de predição e ranking divergem.
He et al. (2017); Ferrari Dacrema et al. (2019, 2021); Rendle et al. (2020)	Modelos neurais e reprodutibilidade	Justificativa do escopo enxuto: baselines clássicos bem ajustados como referência confiável.
Herlocker et al. (2004); Shani e Gunawardana (2011); Järvelin e Kekäläinen (2002)	Métricas	Separação entre RMSE/MAE e Precision@k, Recall@k, NDCG@k; centralidade das métricas de ranking.
Krichene e Rendle (2020); Meng et al. (2020); Castells e Moffat (2022)	Protocolo experimental	Ranking exaustivo sobre todos os itens; explicitação da estratégia de divisão; atenção a vieses de popularidade.
Ziegler et al. (2005); Wan e McAuley (2018); Zajac (2017); Kula (2015); Schein et al. (2002)	Domínio de livros	Diversidade como valor para incentivo à leitura; uso do sinal "quero ler"; dataset; extensão híbrida.
McKinney (2010); Harris et al. (2020); Virtanen et al. (2020); Pedregosa et al. (2011); Hug (2020); Frederickson (2016)	Ferramentas	Definição das bibliotecas Python do projeto.

Fonte: elaborado pelo autor.

Diante da literatura revisada, o sistema proposto posiciona-se como uma aplicação de filtragem colaborativa clássica, com modelos de vizinhança e de fatores latentes, ao domínio de livros, diferenciando-se dos trabalhos acadêmicos de benchmark por sua finalidade extensionista: servir de base aberta e documentada para bibliotecas públicas e escolares. Sua contribuição metodológica reside na adoção rigorosa das recomendações recentes sobre avaliação, com separação explícita entre erro de predição e qualidade de ranking, ranking exaustivo e protocolo de divisão explicitado, e na priorização de poucos modelos bem ajustados, em linha com as evidências de Ferrari Dacrema et al. (2019, 2021) e Rendle et al. (2020). A dimensão social do trabalho dialoga, por fim, com os achados de Ziegler et al. (2005) sobre o valor da diversidade na recomendação de livros, aspecto que poderá ser explorado como extensão na etapa final.

REFERÊNCIAS

- ADOMAVICIUS, Gediminas; TUZHILIN, Alexander. Toward the next generation of recommender systems: a survey of the state-of-the-art and possible extensions. **IEEE Transactions on Knowledge and Data Engineering**, v. 17, n. 6, p. 734-749, 2005.
- AGGARWAL, Charu C. **Recommender Systems: The Textbook**. Cham: Springer, 2016.
- CASTELLS, Pablo; MOFFAT, Alistair. Offline recommender system evaluation: challenges and new directions. **AI Magazine**, v. 43, n. 2, p. 225-238, 2022.
- CREMONESI, Paolo; KOREN, Yehuda; TURRIN, Roberto. Performance of recommender algorithms on top-N recommendation tasks. In: ACM CONFERENCE ON RECOMMENDER SYSTEMS (RecSys), 4., 2010, Barcelona. **Proceedings [...]**. New York: ACM, 2010. p. 39-46.
- FERRARI DACREMA, Maurizio; CREMONESI, Paolo; JANNACH, Dietmar. Are we really making much progress? A worrying analysis of recent neural recommendation approaches. In: ACM CONFERENCE ON RECOMMENDER SYSTEMS (RecSys), 13., 2019, Copenhagen. **Proceedings [...]**. New York: ACM, 2019. p. 101-109.
- FERRARI DACREMA, Maurizio; BOGLIO, Simone; CREMONESI, Paolo; JANNACH, Dietmar. A troubling analysis of reproducibility and progress in recommender systems research. **ACM Transactions on Information Systems**, v. 39, n. 2, art. 20, 2021.
- FREDERICKSON, Ben. **Implicit: fast Python collaborative filtering for implicit datasets**. 2016. Disponível em: <https://github.com/benfred/implicit>. Acesso em: 1 out. 2026.
- HARRIS, Charles R. et al. Array programming with NumPy. **Nature**, v. 585, p. 357-362, 2020.
- HE, Xiangnan; LIAO, Lizi; ZHANG, Hanwang; NIE, Liqiang; HU, Xia; CHUA, Tat-Seng. Neural collaborative filtering. In: INTERNATIONAL CONFERENCE ON WORLD WIDE WEB (WWW), 26., 2017, Perth. **Proceedings [...]**. Geneva: IW3C2, 2017. p. 173-182.
- HERLOCKER, Jonathan L.; KONSTAN, Joseph A.; BORCHERS, Al; RIEDL, John. An algorithmic framework for performing collaborative filtering. In: ANNUAL INTERNATIONAL ACM SIGIR CONFERENCE, 22., 1999, Berkeley. **Proceedings [...]**. New York: ACM, 1999. p. 230-237.
- HERLOCKER, Jonathan L.; KONSTAN, Joseph A.; TERVEEN, Loren G.; RIEDL, John T. Evaluating collaborative filtering recommender systems. **ACM Transactions on Information Systems**, v. 22, n. 1, p. 5-53, 2004.
- HU, Yifan; KOREN, Yehuda; VOLINSKY, Chris. Collaborative filtering for implicit feedback datasets. In: IEEE INTERNATIONAL CONFERENCE ON DATA MINING (ICDM), 8., 2008, Pisa. **Proceedings [...]**. Washington: IEEE, 2008. p. 263-272.

HUG, Nicolas. Surprise: a Python library for recommender systems. **Journal of Open Source Software**, v. 5, n. 52, art. 2174, 2020.

INSTITUTO PRÓ-LIVRO. **Retratos da Leitura no Brasil**. 5. ed. São Paulo: Instituto Pró-Livro; Itaú Cultural, 2020.

JÄRVELIN, Kalervo; KEKÄLÄINEN, Jaana. Cumulated gain-based evaluation of IR techniques. **ACM Transactions on Information Systems**, v. 20, n. 4, p. 422-446, 2002.

KOREN, Yehuda. Factorization meets the neighborhood: a multifaceted collaborative filtering model. In: ACM SIGKDD INTERNATIONAL CONFERENCE ON KNOWLEDGE DISCOVERY AND DATA MINING (KDD), 14., 2008, Las Vegas. **Proceedings** [...]. New York: ACM, 2008. p. 426-434.

KOREN, Yehuda; BELL, Robert; VOLINSKY, Chris. Matrix factorization techniques for recommender systems. **Computer**, v. 42, n. 8, p. 30-37, 2009.

KRICHENE, Walid; RENDLE, Steffen. On sampled metrics for item recommendation. In: ACM SIGKDD INTERNATIONAL CONFERENCE ON KNOWLEDGE DISCOVERY AND DATA MINING (KDD), 26., 2020, Virtual Event. **Proceedings** [...]. New York: ACM, 2020. p. 1748-1757.

KULA, Maciej. Metadata embeddings for user and item cold-start recommendations. In: WORKSHOP ON NEW TRENDS ON CONTENT-BASED RECOMMENDER SYSTEMS (CBRecSys), 2., 2015, Vienna. **Proceedings** [...]. Aachen: CEUR-WS, 2015. v. 1448, p. 14-21.

McKINNEY, Wes. Data structures for statistical computing in Python. In: PYTHON IN SCIENCE CONFERENCE (SciPy), 9., 2010, Austin. **Proceedings** [...]. 2010. p. 56-61.

MENG, Zaiqiao; McCREADIE, Richard; MACDONALD, Craig; OUNIS, Iadh. Exploring data splitting strategies for the evaluation of recommendation models. In: ACM CONFERENCE ON RECOMMENDER SYSTEMS (RecSys), 14., 2020, Virtual Event. **Proceedings** [...]. New York: ACM, 2020. p. 681-686.

NING, Xia; DESROSIERS, Christian; KARYPIS, George. A comprehensive survey of neighborhood-based recommendation methods. In: RICCI, F.; ROKACH, L.; SHAPIRA, B. (ed.). **Recommender Systems Handbook**. 2. ed. Boston: Springer, 2015. p. 37-76.

ORGANIZAÇÃO DAS NAÇÕES UNIDAS. **Transformando nosso mundo: a Agenda 2030 para o Desenvolvimento Sustentável**. Nova York: ONU, 2015.

PEDREGOSA, Fabian et al. Scikit-learn: machine learning in Python. **Journal of Machine Learning Research**, v. 12, p. 2825-2830, 2011.

RENDLE, Steffen; FREUDENTHALER, Christoph; GANTNER, Zeno; SCHMIDT-THIEME, Lars. BPR: Bayesian personalized ranking from implicit feedback. In: CONFERENCE ON UNCERTAINTY IN ARTIFICIAL INTELLIGENCE (UAI), 25., 2009, Montreal. **Proceedings** [...]. Arlington: AUAI Press, 2009. p. 452-461.

RENDLE, Steffen; KRICHENE, Walid; ZHANG, Li; ANDERSON, John. Neural collaborative filtering vs. matrix factorization revisited. In: ACM CONFERENCE ON RECOMMENDER SYSTEMS (RecSys), 14., 2020, Virtual Event. **Proceedings** [...]. New York: ACM, 2020. p. 240-248.

RICCI, Francesco; ROKACH, Lior; SHAPIRA, Bracha (ed.). **Recommender Systems Handbook**. 3. ed. New York: Springer, 2022.

SARWAR, Badrul; KARYPIS, George; KONSTAN, Joseph; RIEDL, John. Item-based collaborative filtering recommendation algorithms. In: INTERNATIONAL CONFERENCE ON WORLD WIDE WEB (WWW), 10., 2001, Hong Kong. **Proceedings** [...]. New York: ACM, 2001. p. 285-295.

SCHEIN, Andrew I.; POPESCU, Alexandrin; UNGAR, Lyle H.; PENNOCK, David M. Methods and metrics for cold-start recommendations. In: ANNUAL INTERNATIONAL ACM SIGIR CONFERENCE, 25., 2002, Tampere. **Proceedings** [...]. New York: ACM, 2002. p. 253-260.

SHANI, Guy; GUNAWARDANA, Asela. Evaluating recommendation systems. In: RICCI, F.; ROKACH, L.; SHAPIRA, B.; KANTOR, P. B. (ed.). **Recommender Systems Handbook**. Boston: Springer, 2011. p. 257-297.

VIRTANEN, Pauli et al. SciPy 1.0: fundamental algorithms for scientific computing in Python. **Nature Methods**, v. 17, p. 261-272, 2020.

WAN, Mengting; McAULEY, Julian. Item recommendation on monotonic behavior chains. In: ACM CONFERENCE ON RECOMMENDER SYSTEMS (RecSys), 12., 2018, Vancouver. **Proceedings** [...]. New York: ACM, 2018. p. 86-94.

ZAJAC, Zygmunt. **goodbooks-10k: a new dataset for book recommendations**. FastML, 2017. Disponível em: <https://github.com/zygmuntz/goodbooks-10k>. Acesso em: 4 set. 2026.

ZIEGLER, Cai-Nicolas; McNEE, Sean M.; KONSTAN, Joseph A.; LAUSEN, Georg. Improving recommendation lists through topic diversification. In: INTERNATIONAL CONFERENCE ON WORLD WIDE WEB (WWW), 14., 2005, Chiba. **Proceedings** [...]. New York: ACM, 2005. p. 22-32.