

Projeto Aplicado III – Etapa 2

Prova de Conceito: Sistema de Recomendação de Livros (goodbooks-10k)

Enzo Enrico Braga Cavalcante (RA 10744145) – Guarulhos, outubro de 2026

Este relatório resume as atividades técnicas da Etapa 2: definição das bibliotecas Python, análise exploratória da base, tratamento dos dados, definição da técnica de recomendação, treinamento de modelos iniciais como prova de conceito e definição da forma de avaliação. O conteúdo aqui apresentado será incorporado às seções de Metodologia e Resultados do documento do projeto na Etapa 3. Todo o código está no repositório do projeto (scripts 01_edu.py e 02_poc_modelos.py).

1 Bibliotecas Python definidas

Biblioteca	Versão	Uso no projeto
pandas / NumPy / SciPy	2.x / 2.x / 1.x	Carga dos CSV, EDA, matrizes esparsas (CSR), SVD truncado (scipy.sparse.linalg.svds)
scikit-learn	1.x	Normalização L2 das linhas (similaridade do cosseno)
scikit-surprise	1.1.5	SVD com vieses (Funk-SVD) treinado por SGD para predição de nota
implicit	0.7.3	ALS para feedback implícito (Hu, Koren e Volinsky, 2008)
Matplotlib	3.x	Figuras da EDA e dos resultados

As métricas de ranking (Precision@k, Recall@k, NDCG@k) foram implementadas pelo autor em NumPy, para garantir o ranking exaustivo sobre todos os itens e total transparência no cálculo.

2 Análise exploratória da base

A base goodbooks-10k contém 5.976.479 avaliações de 53.424 usuários sobre 10.000 livros. Não há valores ausentes nem pares (usuário, livro) duplicados em ratings.csv. A esparsidade da matriz usuário-item é de 98,88%. A nota média é 3,92 e a distribuição é fortemente enviesada para o positivo: 69% das notas são 4 ou 5 e apenas 8% são 1 ou 2 (Figura 1).




Figura 1 – Distribuição das notas.

Cada usuário possui entre 19 e 200 avaliações (mediana 111; quartis 96 e 128): a base foi construída com usuários relativamente ativos, o que atenua a partida a frio de usuários. Já os livros apresentam cauda longa acentuada: entre 8 e 22.806 avaliações (mediana 248, média 598), e os 20% de livros mais populares concentram 67,5% de todas as avaliações (Figuras 2 e 3). Isso tem duas consequências para o projeto: a recomendação por popularidade é um baseline razoável e deve ser batida; e as métricas de ranking tenderão a favorecer modelos que recomendam itens populares, o que precisa ser discutido na análise.

Figura 2 – Distribuição de avaliações por usuário e por livro




Figura 2 – Avaliações por usuário (a) e por livro (b), escala logarítmica.




Figura 3 – Curva de concentração: 20% dos livros respondem por 67,5% das avaliações.

Em books.csv, os campos com ausências são isbn (700), isbn13 (585), original_title (585), language_code (1.084) e original_publication_year (21); nenhum deles é usado pelos modelos colaborativos. A mediana do ano de publicação original é 2004 (Figura 4), e 87% dos livros com idioma informado estão em inglês. Os livros mais avaliados são best-sellers de ficção jovem e clássicos escolares (The Hunger Games, Harry Potter, To Kill a Mockingbird, Twilight, The Great Gatsby). O arquivo to_read.csv traz 912.705 marcações "quero ler", sinal implícito que será explorado em etapas futuras. Em book_tags.csv, as tags mais frequentes são de organização pessoal (to-read, currently-reading, favorites, books-i-own) e precisam ser filtradas antes de qualquer uso como atributo; depois delas aparecem gêneros úteis (fiction, fantasy, young-adult, classics, romance, mystery, non-fiction).




Figura 4 – Ano de publicação original dos livros (truncado em 1900).

3 Tratamento e preparação dos dados

- Reindexação: `user_id` e `book_id` já são inteiros contíguos a partir de 1; foram convertidos para índices 0-based.
- Verificação de integridade: ausência de nulos e de duplicatas confirmada; sem necessidade de filtros de atividade mínima, pois o dataset já garante ≥ 19 avaliações por usuário e ≥ 8 por livro.
- Divisão treino/teste por usuário (holdout): 20% das avaliações de cada usuário foram sorteadas para teste (semente 42), resultando em 4.802.569 avaliações de treino e 1.173.910 de teste. Como todo usuário aparece em ambos os conjuntos, o protocolo avalia a capacidade de personalização e não a partida a frio.
- Representação: matriz esparsa CSR 53.424×10.000 com as notas de treino; versão centrada por item (nota – média do item) para o k-NN; versão binária (1 = avaliou) para PureSVD e ALS.
- Definição de relevância para o ranking: um item do teste é relevante se recebeu nota ≥ 4 (limiar acima da mediana).

4 Técnica de recomendação definida

Adotou-se filtragem colaborativa, nas duas famílias descritas no Referencial Teórico: vizinhança item-item (cosseno sobre notas centradas, $k = 50$ vizinhos) e fatoração de matrizes, em três variantes — SVD com vieses (predição de nota; 50 fatores, 20 épocas, $\text{lr} = 0,005$, $\text{reg} = 0,02$), PureSVD (SVD truncado da matriz binária, 50 fatores) e ALS implícito (64 fatores, 15 iterações, confiança $\alpha = 20$). Como baselines não personalizados: média global, média do item e popularidade (número de avaliações). Os hiperparâmetros são os padrões da literatura e não foram ajustados nesta etapa; o ajuste é objeto da Etapa 3.

5 Forma de avaliação definida

Seguindo a orientação docente e a literatura (Cremonesi, Koren e Turrin, 2010; Krichene e Rendle, 2020), separam-se dois tipos de avaliação:

- **Erro de predição de nota:** RMSE e MAE calculados sobre as 1,17 milhão de avaliações do teste, apenas para os modelos que produzem uma nota.

- **Qualidade da lista (critério central):** para cada usuário, pontuam-se todos os 10.000 livros, mascaram-se os já lidos no treino e tomam-se os 10 melhores. Precision@10 = fração dos 10 que são relevantes; Recall@10 = fração dos relevantes do usuário que estão nos 10; NDCG@10 = ganho descontado pela posição, normalizado pelo ideal. Ranking exaustivo, sem amostragem de negativos; média sobre os 53.410 usuários com ao menos um item relevante no teste.

6 Resultados da prova de conceito

Modelo	RMSE	MAE	Precision@10	Recall@10	NDCG@10
Média global	0,991	0,774	—	—	—
Média do item / Popularidade	0,953	0,763	0,078	0,052	0,089
Item-kNN (cosseno, k=50)	0,837	0,614	0,197	0,126	0,240
SVD com vieses (Funk, 50 fatores)	0,828	0,640	0,009	0,007	0,010
PureSVD (50 fatores, binário)	—	—	0,226	0,150	0,270
ALS implícito (64 fatores)	—	—	0,208	0,141	0,230

Tabela 1 – Resultados no conjunto de teste (holdout 20% por usuário). Melhor valor de cada coluna: SVD (RMSE), Item-kNN (MAE), PureSVD (ranking).

Figura 5 – Prova de conceito: métricas de ranking vs. erro de predição




Figura 5 – Métricas de ranking (a) e erro de predição (b) por modelo.

Principal achado: as duas famílias de métricas apontam vencedores diferentes. O SVD com vieses obtém o menor RMSE (0,828), mas produz a pior lista de todas — pior até que a popularidade (NDCG@10 de 0,010 contra 0,089). Ao ordenar pela nota prevista, ele coloca no topo livros de nicho com média altíssima e pouquíssimas avaliações (coleções de Calvin and Hobbes, por exemplo), que o usuário dificilmente consumirá. Já o PureSVD e o ALS, que não preveem nota alguma, geram as melhores listas (NDCG@10 de 0,270 e 0,230). O Item-kNN é o único modelo competitivo nas duas tarefas. O resultado reproduz exatamente o fenômeno descrito por Cremonesi, Koren e Turrin (2010) e confirma que a conclusão sobre "qual modelo é melhor" deve se basear nas métricas de ranking.

Todos os modelos personalizados superaram o baseline de popularidade em ranking por ampla margem (NDCG@10 de 2,6 a 3,0 vezes maior), o que indica que há sinal colaborativo forte na base, apesar da cauda longa.

Exemplo qualitativo (usuário 4765). Livros mais bem avaliados no treino: Brave New World; A Midsummer Night's Dream; High Fidelity; Slaughterhouse-Five; Our Town. Top-5 do SVD com vieses: The Divan; The Revenge of the Baby-Sat; The Complete Calvin and Hobbes; The

Essential Calvin and Hobbes: A Calvin and Hobbes Treasury; Homicidal Psycho Jungle Cat: A Calvin and Hobbes Collection. Top-5 do ALS: The Lion, the Witch, and the Wardrobe (Chronicles of Narnia, #1); The Outsiders; A Wrinkle in Time (A Wrinkle in Time Quintet, #1); Hamlet; The Magician's Nephew (Chronicles of Narnia, #6). A lista do ALS é coerente com um leitor de clássicos e teatro (e acerta "Macbeth", presente nos relevantes do teste); a do SVD é dominada por quadrinhos de nicho.

7 Próximos passos (Etapa 3)

- Ajustar hiperparâmetros de Item-kNN (k , shrinkage), PureSVD (n° de fatores) e ALS (fatores, regularização, α) com conjunto de validação separado do teste.
- Avaliar sensibilidade a k (5, 10, 20) e ao limiar de relevância; reportar intervalos de confiança por usuário.
- Analisar o viés de popularidade das listas (cobertura de catálogo e popularidade média dos itens recomendados), relevante para o objetivo de ampliar repertório de leitura.
- Incorporar `to_read.csv` como feedback implícito adicional no ALS e verificar o ganho.
- Redigir Metodologia e Resultados no documento do projeto a partir deste relatório.

Repositório: <https://github.com/Enzo-Enrico/Projeto-Aplicado-III-Sistema-Recomendacao>